

ADS1293 Giyilebilir Telemetri Sistemi: Uçtan Uca Ham Veri İşleme ve İleri Yapay Zeka Mimarisi

Bu belge, Texas Instruments ADS1293 çipinden elde edilen ham EKG sinyallerinin veri bilimi, istatistiksel analiz, ileri düzey sinyal işleme, derin öğrenme (Deep Learning) ve makine öğrenmesi algoritmalarıyla nasıl uçtan uca anlamlandırılacağını detaylandırmaktadır.

Belgenin temel amacı; hastanın belinde taşınan hareketli bir sistemde (Giyilebilir Holter) ortaya çıkan devasa "ham veri" kaosunu çözmek ve fraktal sinyal analizi, uzamsal-zamansal sinir ağları ile tıbbi açıklanabilirlik (XAI) pratiklerini entegre ederek, dünya standartlarında (State-of-the-Art) bir medikal yazılım mimarisi kurgulamaktır.

1. Donanım-Yazılım Arayüzü: Ham Veri Akışının (Raw Data Pipeline)

Yönetimi

Bu projenin en kritik ve mühendislik açısından en zorlayıcı adımı "**Ham Verinin İşlenmesi**" dir. Hastanın beline takılan ve kablolarla göğse bağlanan hareketli bir cihaz, durağan hastane monitörlerinden çok daha gürültülü ve kompleks bir veri üretir. Veri kaybını önlemek ve doğru dijitalleştirme yapmak işin temelidir.

1.1 Sigma-Delta ($\Sigma\Delta$) ADC ve Kesintisiz Veri Akışı

Kalpten cilde ulaşan mikrovolt düzeyindeki potansiyel, çip içerisinde ardışık bir aşırı örnekleme (Oversampling) tabi tutulur. Düşük frekanslı EKG sinyali, "Sinc" filtre zinciri sayesinde yüksek frekanslı kuantalama gürültüsünden arındırılır (Noise Shaping).

- **Ring Buffer (Dairesel Bellek) Mimarisi:** ADS1293'ün SPI arayüzünden saniyede yüzlerce veri paketi (örneğin 500 Hz) akar. İşlemci bu hıza yetişemezse paket düşmesi (Data Drop) yaşanır. Bunu önlemek için yazılım katmanında bir Ring Buffer ve Interrupt (Kesme) mimarisi kurularak, ham veriler sıraya dizilir ve asenkron olarak işlenir.

1.2 24-Bit Ham Verinin Matris Dönüşümü

Cihazın üzerindeki mini ekranda EKG eğrisinin canlı akabilmesi ve verinin yapay zekaya gitmesi için SPI bit katarının anlık çözülmesi gerekir. 24-bit Two's Complement formatındaki raw (ham) veri, cihazın içindeki işlemcide şu formülle gerçek dünyaya (μV) çevrilir:

- **V_LSB Formülasyonu:** $V_{LSB} = (V_{REF}) / (Gain * (2^{23}))$
- **Elektriksel Genlik:** $(2.4 V) / (3.5 * 8,388,608) \approx 0.081711 \mu V / LSB$
- Gelen her ham byte, O(1) zaman karmaşıklığında bu katsayı ile çarpılarak C++ veya Python'da doğrudan elektriksel genliğe ölçeklenir.

Basit Özet: Cihaz, bilgisayara kalbin atışını "1.5 Volt" diye göndermez; sadece karmaşık bir 0 ve 1 dizisi yollar. Biz bu adımda yazdığımız formülle o şifreli bilgisayar dilini, tıp dilindeki

"mikrovolt" seviyesine çeviriyoruz. Ayrıca veriler çok hızlı geldiği için, gelen her sayıyı önce bir "bekleme odasına" (Ring Buffer) alıyor, sırayla işliyoruz ki hiçbir kalp atışı kaybolmasın.

2. Giyilebilir Sistemlerde Ham Veri Temizleme ve Gürültü İzolasyonu

Giyilebilir bir cihazda "Kablo Sürtünme Gürültüsü" (Motion Artifact) ve yürüyüşten kaynaklı "Kas Gürültüsü" (EMG) devasa bir problemdir.

2.1 Düşük Frekans Kayması (Baseline Wander) ve Sıfır-Fazlı İzolasyon

Hastanın yürümesi ve nefes alması, sinyale 0.1-0.5 Hz arasında periyodik bir parazit ekleyerek EKG çizgisini yukarı aşağı dalgalandırır. Standart IIR filtreler EKG dalgalarının zaman eksenindeki yerini sağa kaydırarak QT süresini bozar.

- **Çözüm (FiltFilt):** Sinyali zaman ekseninde önce ileri, sonra geri geçirerek faz kaymasını sıfırlayan **Forward-Backward (Sıfır-Fazlı)** filtreleme kullanılır.

```
python

# Python FiltFilt Uygulama Mimarisi (Ham Veri Temizliği)
import numpy as np
from scipy.signal import butter, filtfilt

def zero_phase_baseline_filter(raw_data, lowcut=0.5, highcut=40.0, fs=500.0, order=4):
    """
    Sıfır-fazlı filtre ile hareket artefaktlarını (Baseline Wander)
    EKG morfolojisini (%100) koruyarak temizler.
    """
    nyq = 0.5 * fs
    b, a = butter(order, [lowcut/nyq, highcut/nyq], btype='band')
    clean_data = filtfilt(b, a, raw_data)
    return clean_data
```

2.2 Kapsamlı Wavelet Denoising (Dalgacık Dönüşümü)

Hasta hareket ettiğinde iskelet kaslarından EKG'nin içine giren EMG gürültüsü, QRS (kalp atışı) sivrililiği ile aynı frekanstadır.

- **Çözüm:** Klasik filtreler tepe noktalarını ezer. Bu yüzden **Daubechies (db4) Dalgacık Dönüşümü** kullanılır. Evrensel eşik ($\sigma * \sqrt{2 * \log(N)}$) kullanılarak, gürültü karakterindeki katsayılar "Soft Thresholding" ile sıfırlanır, QRS morfolojisi %100 korunur.

2.3 Optimizasyon İçin Z-Score (Standartlaştırma) Geometrisi

Derin sinir ağlarının ağırlık güncellemelerinde patlayan gradyan problemini önlemek için EKG sinyali normalize edilmelidir.

- Min-Max ([0, 1]) yerine Z-Score Standardization $(X - \mu) / \sigma$ kullanılır. Çünkü Min-Max, elektrotun cilde bir anlık sürtünmesinde (Outlier) tüm sağlıklı veriyi sıfıra sıkıştırır. Z-Score, modelin genliğe değil sinyalin "şekline" odaklanmasını mecbur kılar.

Basit Özet: Hastanın yürümesi veya kablonun kıyafete sürtmesi, grafiğin üzerine bir çizirti bırakır. Klasik süzgeçler bu kiri silerken kalp dalgalarını da ezer, şeklini bozar. Bizim kullandığımız *Sıfır-Fazlı* ve *Dalgacık Dönüşümü* algoritmaları, sanki bir fotoğrafın sadece pürüzlerini silen yapay zeka fırçası gibi ana resmi hiç bozmadan saniyeler içinde pürüzsüzleştirir.

3. EKG Sinyalinin Morfolojik Analizi ve Özellik Çıkarımı

Makine öğrenmesi modellerinin (XGBoost gibi) karar verebilmesi için, temizlenen ham verinin içindeki tıbbi anlamların çıkarılması (Feature Engineering) gerekir.

3.1 Zaman Serisinde Dalga Tespiti ve Pan-Tompkins Matematiği

Kalp atış hızını bulmak için en büyük tepe olan R-tepesinin milisaniyelik hassasiyetle bulunması şarttır. Eşik (threshold) yöntemleri hareketli veride çöker.

- **Pan-Tompkins Algoritması:** Sinyal sırasıyla Türev alma (eğimi bulma), Karesini alma (negatifleri pozitifçe çevirip QRS'i belirginleştirme) ve Hareketli Pencere İntegrali (Moving Window Integration) aşamalarından geçirilerek R-tepesi hatasız olarak izole edilir.

3.2 İleri İstatistiksel ve Fraktal Metrikler

- **Zaman Alanı (Time-Domain):** SDNN (R-R aralıklarının standart sapması) ve pNN50. T-Wave Alternans (TWA) varyasyonu çıkarılarak ani ölüm risk modellerine mikro-parametreler sağlanır.

- **Frekans Alanı (Frequency-Domain):** Welch metodu ile Güç Spektral Yoğunluğu (PSD) çıkarılır. LF/HF (Low Frequency / High Frequency) oranı hastanın otonomik stres dengesini gösterir.

- **Kaos ve Non-Lineer Dinamikler:**

Örneklem Entropisi (Sample Entropy - SampEn): R-R zaman serisinin karmaşıklığını ölçer. Kalp yetmezliğinde ritim fazla düzenli hale gelir (mekanikleşir) ve Entropi düşer.

Basit Özet: Kalbimiz tık-tık diye robot gibi sabit atmaz; gizli bir düzensizliği, bir "kaosu" vardır. Eğer kalp aşırı düzenli atmaya başlarsa bu aslında bir hastalık belirtisidir (Entropinin düşmesi). Biz, matematiksel formüllerle o sinyalin içindeki karmaşayı hesaplayıp modele "Bak bu kalp çok robotik atıyor, hastada kalp yetmezliği olabilir" demesini öğretiyoruz.

4. Makine Öğrenmesi İçin Veri Artırma (Data Augmentation) ve Dengesizlik Çözümü

Modelin "Hastanede / Gerçek Dünyada" karşılaşacağı veri kirliliğini laboratuvarında simüle edebilmesi başarının anahtarıdır.

4.1 Çok Boyutlu Manifoldlarda Sınıf Dengesizliği Çözümü (SMOTE)

Nadir görülen (Ventriküler Fibrilasyon vs.) vakaların azlığı modeli "Accuracy Paradox'a" sürükler (Model her şeye "Normal" der ve %95 başarı elde eder).

1. **Borderline-SMOTE:** Standart SMOTE körleme veri üretir. Borderline-SMOTE, yalnızca "Normal" sınıfla "Hastalık" sınıfının tehlikeli bir şekilde kesiştiği karar sınırındaki (Decision Boundary) hastalara odaklanır ve o sınıra sentetik hasta üretir.

```
python

# Borderline-SMOTE ile Gelişmiş Sentetik Aritmi Verisi Üretimi
from imblearn.over_sampling import BorderlineSMOTE

# k_neighbors ile sınır bölgesindeki riskli vakaları tespit edip çoğaltır
smote = BorderlineSMOTE(sampling_strategy='minority', k_neighbors=5, m_neighbors=10)
X_balanced, y_balanced = smote.fit_resample(X_train_features, y_train_labels)
```

4.2 Zaman Serisinde İleri Augmentation (Bozma ve Zenginleştirme)

Eğitim setini zenginleştirmek için veriye deterministik bozulmalar (Data Corruption) enjekte edilir:

- **Temporal Warping (Zamansal Çarpıtma):** Sinyalin bazı bölümlerinin hızlandırılıp yavaşlatılmasıdır. Farklı hastaların kalplerinin farklı anlarda kasılmasını simüle eder.
- **Sensor Drop-out (Elektrot Temassızlığı):** Giyilebilir bir cihazda, elektrotun terlemeden dolayı ciltten anlık ayrılmasını modele öğretmek için, EKG serisinin rastgele seçilen kısımlarının matris genliği (0.0) değerine çekilir (Dropout).

Basit Özet: Yapay zekayı bir şoför gibi düşünün. Sadece boş otobanda eğiterseniz şehir trafiğinde kaza yapar. Giyilebilir cihaz kullanmak şehir trafiği gibidir; elektrot çıkabilir, hasta koşabilir. Bu yüzden laboratuvarında veriye bilerek "kablo kopma" anlarını simüle ediyor ve az rastlanan hastalıkları algoritmalarla çoğaltıyoruz.

5. Uzamsal-Zamansal (Spatio-Temporal) Derin Öğrenme Mimarisi

Piyasadaki tekil algoritmaların kapasitesi gerçek EKG anomali spektrumunu yakalamaya yetmez. Bu projede, alanın en güçlü, En İleri (State-of-the-Art) Hibrit yapısı önerilmektedir: **1D-CNN + BiLSTM + Attention Mechanism**.

5.1 Mimarinin Anatomisi ve Algoritmik Gerekçeler

- Aşama 1: 1D-CNN (Mekansal / Spatial Örüntü Avcısı):** Ham 1D veri evrişim katmanına girer. Farklı Kernel boyutları (kernel_size=31 yavaş T dalgasını, kernel_size=7 keskin QRS'i yakalamak için) paralel uygulanır. **Batch Normalization** ile normalize edilerek İç Ortak Değişken Kayması önlenir.
- Aşama 2: BiLSTM (Zamansal / Temporal Bağlam):** CNN'den çıkan morfolojik haritalar, zaman serisi mantığıyla çalışan Çift Yönlü Uzun-Kısa Süreli Bellek (BiLSTM) ağına verilir. Model sinyali ardışık atımların (AFib gibi) uzak mesafeli bağımlılıklarını öğrenir.
- Aşama 3: Bahdanau / Luong Attention (Dikkat Mekanizması):** Modelin tüm sinyale eşit ağırlık vermesi yanlıştır. Dikkat Katmanı, sadece aritmik dalgalara (kriz anına) yüksek katsayı (ağırlık) atar.

```
python

# PyTorch Tabanlı 1D-CNN + BiLSTM Hibrit Mimari Taslağı
import torch.nn as nn

class ECG_Hybrid_Model(nn.Module):
    def __init__(self):
        super(ECG_Hybrid_Model, self).__init__()
        # Özellik Çıkarıcı: 1 Boyutlu Evrişim
        self.conv1 = nn.Conv1d(in_channels=1, out_channels=32, kernel_size=15, stride=2)
        self.bn1 = nn.BatchNorm1d(32)
        self.relu = nn.ReLU()
        # Zaman Serisi Modellemesi: Çift Yönlü LSTM
        self.lstm = nn.LSTM(input_size=32, hidden_size=64, bidirectional=True, batch_first=True)
        # Sınıflandırma Katmanı
        self.fc = nn.Linear(128, num_classes) # 64 * 2 (Bidirectional)

    def forward(self, x):
        x = self.relu(self.bn1(self.conv1(x)))
        x = x.permute(0, 2, 1) # LSTM için [Batch, Seq_Len, Features] formatı
        lstm_out, _ = self.lstm(x)
        # Sadece son zaman adımının çıktısı
        out = self.fc(lstm_out[:, -1, :])
        return out
```

5.2 Algoritmik Performans Analiz Matrisi

Algoritma Tipi	Yakaladığı En İyi Anomali Tipi	İşlemci (Donanım) İhtiyacı	Öznitelik İhtiyacı
XGBoost	Tablosal veriler, Ritim Analizi, Stres	Çok Düşük (Mikrodenetleyici)	Yüksek (Matematiksel çıkarım)
1D-CNN	Morfolojik Bozukluklar (ST Elevasyonu)	Yüksek (GPU hızlandırma)	Yok (Ham sinyali kullanır)

BiLSTM	Ardışık Ritim Bozuklukları (AFib, PVC)	Yüksek (GPU veya TPU)	Yok (Ham sinyali kullanır)
Hibrit Ağ	Tüm Olası Komplikasyonlar	Çok Yüksek (Bulut / Kapsamlı GPU)	Yok (Sinyalden kendi öğrenir)

Basit Özet: Sinyali anlamak için üç uzmanın aynı anda çalıştığını hayal edin. **1D-CNN**, EKG şekilsel bozukluklarını avlar. **BiLSTM**, zaman tüneline dolaşarak ritimdekiler gecikmeleri arar. **Attention** ise "Doğrudan krizin yaşandığı tepeye odaklanın" der. Bu hibrit yapı sayesinde en zor ritim bozukluklarını kaçırmayız.

6. Model Eğitimi, Optimizasyon ve Kayıp Fonksiyonları

6.1 Cross-Entropy'nin Çöküşü ve Focal Loss Matematiği

Dengesiz veri setlerinde standart Çapraz Entropi (Cross-Entropy), %90 oranındaki "Normal" sınıftan gelen kolay gradyan güncellemeleriyle boğulur.

- **Focal Loss (Odaklanmış Kayıp):** Formülündeki $(1 - p_t)^\gamma$ faktörü sayesinde, modelin çok iyi bildiği örneklerin kayıp değerini sıfıra indirir. Zor ayırt edilen nadir aritmi sınıflarından gelen hatayı katlayarak büyütür. Ağ, zor örneklerle odaklanmak zorunda bırakılır.

6.2 AdamW Optimizasyonu ve Cosine Annealing

Ağın sahte (yerel) minimumlara takılmasını önlemek için **Cosine Annealing Warm Restarts** zamanlayıcısı kullanılır. Öğrenme oranı kademeli olarak küçülür, dibe vurduğunda aniden yüksek bir değere sıçrayarak ağırlıkları sarsar ve modeli daha iyi bir noktaya yönlendirir.

6.3 Transfer Öğrenimi (Transfer Learning)

Modelin "kardiyak fizyolojiyi" öğrenmesi için, on binlerce hastalık **PTB-XL** veya **PhysioNet** veri setlerinde devasa bir Ön-Eğitim (Pre-training) yapılır. İlk katmanlar dondurulur (Freeze) ve sadece son katmanlar ADS1293 verisi ile İnce Ayara (Fine-Tuning) sokulur.

Basit Özet: Yapay zekaya bir konuyu öğretirken, çok kolay bildiği şeylerin üzerinde durmasını engellemeliyiz. **Focal Loss** dediğimiz bir ceza sistemi kullanıyoruz; model "Normal" hastaları kolayca tanıyınca onu ödüllendirmeyi bırakıyoruz. Ayrıca **Transfer Öğrenimi** sayesinde, modeli sıfırdan eğitmek yerine, daha önce tıp okuyup mezun olmuş (milyonlarca EKG görmüş) bir modele kendi verilerimizi okutuyoruz.

7. Gömülü Yapay Zeka (Edge AI) ve Donanımsal Hızlandırma

Giyilebilir cihazın sadece veriyi ileten aptal bir terminal olmaktan çıkıp, anlık kriz uyarısı veren "Akıllı bir Cihaza" dönüşmesi için **Edge AI** zorunludur.

7.1 Model Kuantizasyonu (Quantization-Aware Training)

Derin öğrenme ağırlıkları 32-bit (Float32) formatındadır ve cihazın içindeki işlemcide çalışamaz.

- **Çözüm:** Modelin içindeki tüm değerler 8-bit Tam Sayı (Int8) formatına sıkıştırılır (Quantization). Bu işlem model boyutunu 4 kat küçültürken, cihazın batarya ömrünü haftalara çıkarır. Performans kaybını önlemek için model baştan "Quantization-Aware Training (QAT)" ile eğitilir.

7.2 Pruning (Budama) ve ONNX Çalışma Zamanı

Ağın içerisindeki sıfıra yakın (önemsiz) ağırlık bağlantıları matematiksel olarak kesilip atılır (Weight Pruning). Model, C++ tabanlı cihazda gecikmesiz çalışması için ONNX veya TensorRT formatına dönüştürülür.

Basit Özet: Dev bir yapay zeka beynini o küçük kutunun içine doğrudan sığdıramayız. "Kuantizasyon" ve "Budama" yöntemleriyle, yapay zekanın gereksiz bilgilerini siliyor, dosyayı "zip"liyoruz. Böylece internete ihtiyaç duymadan, kalp krizi riskini doğrudan hastanın belindeki o cihazda anlık tespit edebiliyoruz.

8. Klinik Karar Sınırları ve Açıklanabilir Yapay Zeka (XAI) ile Model Şeffaflığı

8.1 Performans Metrikleri: AUPRC

Tıbbi yapay zekada "Accuracy (Doğruluk)" aldatıcıdır. Araştırmada modelin başarısı **AUPRC (Area Under the Precision-Recall Curve)** ve **F1-Macro Skoru** ile ölçülür. AUPRC, gerçek hastalık başarısını gösteren en net metriktir.

8.2 Karar Sınırı Kalibrasyonu: Youden's J İndeksi

1. ROC eğrisi üzerindeki Optimum Karar Noktası; **Youden's J = Duyarlılık + Özgüllük - 1** formülü ile maksimize edilir. Modelin hasta ilan etme eşiği dinamik olarak (örneğin 0.23'e) düşürülerek, kritik hastalıkların kaçırılması ihtimali minimize edilir.

8.3 Açıklanabilir Yapay Zeka (Explainable AI - XAI) Şeffaflığı

Medikal alanda "Kara Kutu" (Black-Box) modeller güven vermez. Hekim, modelin kararının mantıksal dayanağını görmek ister.

1. **SHAP (XGBoost İçin):** Modelin "*Kararın %45'i Entropi düşüklüğü, %25'i LF/HF dengesizliği nedeniyle*dir." şeklinde oranlı rapor vermesini sağlar.

2. **Grad-CAM (Derin Öğrenme İçin):** Model "ST Yükselmeli Enfarktüs" dediğinde, ısının doğrudan **ST Segmentinin olduğu yere** düşmesi sağlanarak, doktora yapay zekanın fizyolojiyi gerçekten öğrendiği kanıtlanır.

Basit Özet: Yapay zeka %99 doğru çalışsa bile doktora "Neden o kararı verdin?" sorusu yanıtsız kalırsa güven vermez. Bizim sistemimizdeki **Grad-CAM (Isı Haritası)**, EKG çizgisinin üzerine kırmızı renkle bir odak noktası çizer. Yapay zeka doktora adeta; *"Ben bu kişinin hasta olduğunu söyledim çünkü bak çizginin tam şu noktasına baktım, burada bir çöküntü var"* der. Bu sayede yapay zeka şeffaf bir asistana dönüşür.