

ADS1293 İleri Düzey EKG Veri Analitiği, Hibrit Yapay Zeka Mimarileri ve Gerçek Dünya Simülasyon Rehberi

Bu belge, Texas Instruments ADS1293 çipinden elde edilen ham EKG sinyallerinin veri bilimi, istatistiksel analiz, ileri düzey sinyal işleme, derin öğrenme (Deep Learning) ve makine öğrenmesi (Machine Learning) algoritmalarıyla nasıl uçtan uca anlamlandırılacağını detaylandıran, endüstri ve akademi standartlarının zirvesini (State-of-the-Art) yansıtan bir araştırma ve mimari kurgu dokümanıdır.

Belgenin temel amacı; sıradan bir makine öğrenmesi yaklaşımının ötesine geçerek, **fraktal sinyal analizi, uzamsal-zamansal (spatio-temporal) sinir ağları, manifold düzeyinde sentetik veri üretimi ve tıbbi açıklanabilirlik (XAI)** gibi ileri düzey mühendislik pratiklerini ADS1293 verisine entegre etmektir.

1. Verinin Kökleri: ADS1293 Çipinden Çıkan Sinyalin Dijital Anatomisi

Yapay zeka modelinin başarısı, modelin beslendiği veri matrisinin (array) matematiksel karakteristiğini anlamaktan geçer.

1.1 Sigma-Delta ($\Sigma\Delta$) ADC ve Kuantalama (Quantization) Paradigması

Kalpden cilde ulaşan potansiyel (mikrovolt düzeyi), 2. Derece Sigma-Delta modülatöründe ardışık bir aşırı örnekleme (Oversampling) tabi tutulur. Burada modelin öğrenmesi gereken en kritik faktör, düşük frekanslı (0.05-150 Hz) EKG sinyalinin "kuantalama gürültüsünden" (quantization noise) arındırılması sürecidir (Noise Shaping). Dijital "Sinc" filtre zincirinin kestiği yüksek frekanslar, bize son derece yüksek sinyal-gürültü oranına (SNR) sahip pürüzsüz bir dijital matris bırakır.

1.2 24-Bit Verinin Matris Dönüşümü ve Ölçeklendirme

Çipten okunan SPI bit katarı, modelin algılayabileceği skaler değerler değildir; 24-bit Two's Complement formatındadır. Makine öğrenmesi pipeline'ına girmeden önceki mutlak dönüşüm fonksiyonu şu şekildedir:

- **V_LSB Formülasyonu:** $V_{LSB} = (V_{REF}) / (Gain * (2^{23}))$
- **Optimizasyon:** $(2.4 V) / (3.5 * 8,388,608) \approx 0.081711 \mu V / LSB$
- Veritabanına (veya NumPy dizisine) kaydedilen her bir raw (ham) veri, bu LSB katsayısı ile (Vektörizasyon ile $O(1)$ zaman karmaşıklığında) çarpılarak gerçek EKG genliğine ölçeklenir.

Basit Özet : Çip, bilgisayara kalbin atışını "1.5 Volt" diye göndermez; sadece karmaşık bir 0 ve 1 dizisi yollar. Biz bu adımda yazdığımız ufak bir çarpım formülüyle o şifreli bilgisayar dilini, tıp dilindeki "mikrovolt" seviyesine yani gerçek hayattaki elektrik birimine çeviriyoruz. Yabancı bir dili Türkçeye çevirmek gibi düşünebilirsiniz.

2. EKG Verisini Modellemek: Tıbbi Özelliklerin Veri İz Düşümleri

2.1 Zaman Serisinde Dalga Tespiti ve Gradyan Analizi

1. **QRS Kompleksi:** Veri analizindeki en keskin "Gradyan (Türev) Sıçraması" R-tepesinde gerçekleşir. Kalp Hızı Değişkenliği (HRV) için milisaniyelik gecikmelere dahi tahammül yoktur. Bu nedenle R-tepesi tespiti için sadece eşik (threshold) değil, **Pan-Tompkins Algoritması** veya CWT (Sürekli Dalgacık Dönüşümü) tabanlı dinamik yerel maksimum avcılar kullanılır.

2. **P ve T Dalgaları:** Düşük genlikli ve geniş olduklarından modelin algılaması zordur. P dalgasının matris üzerinde yok olması Atriyal Fibrilasyonu (AFib); T dalgasının negatif gradyana (T-wave Inversion) düşmesi iskemiyi modele öğretir.

Basit Özet : Yapay zeka EKG kağıdındaki çizgilere değil, sayılara bakar. P, Q, R, S, T dediğimiz dalgalar model için aslında birer sayı kümesidir. R tepesi veri setindeki "en büyük tepe dağıdır". Modelimiz o dağın zirvesini bulup atımları oradan sayar. Diğer küçük tepelikler kaybolduğunda (örneğin P dalgası yoksa), "Burada bir sorun var" demeyi öğrenir.

3. İleri Düzey Sinyal Temizleme: Sinyalin Faz ve Frekans Bütünlüğünü Koruma

Derin öğrenme modelleri "Gürültü (Noise)" ve "Hastalık (Anomali)" kavramlarını ayırt edemez. Filtreleme aşaması kusursuz olmalıdır.

3.1 Düşük Frekans Kayması (Baseline Wander) ve Sıfır-Fazlı İzolasyon

Hastanın solunum döngüsü, sinyale 0.1-0.5 Hz arasında periyodik bir parazit ekler. Standart bir IIR / Yüksek Geçiren (High-pass) filtre, faz kaymasına (Phase Delay) neden olarak P-Q-R-S-T dalgalarının zaman eksenindeki yerini milisaniyeler bazında sağa kaydırır.

- **Çözüm (FiltFilt):** Forward-Backward (Sıfır-Fazlı) filtreleme kullanılır.

```
python
# Python FiltFilt Uygulama Mimarisi
from scipy.signal import butter, filtfilt

def zero_phase_filter(data, lowcut, highcut, fs, order=4):
    nyq = 0.5 * fs
    low = lowcut / nyq
    high = highcut / nyq
    b, a = butter(order, [low, high], btype='band')
    # Sinyali ileri ve geri geçirerek faz kaymasını sıfırlar
    clean_data = filtfilt(b, a, data)
    return clean_data
```

3.2 Kapsamlı Wavelet Denoising (Dalgacık Dönüşümü)

Yüksek frekanslı kas (EMG) kasılmaları, EKG QRS sivrililiği ile frekans uzayında örtüşür. Butterworth filtreleri bu gürültüyü keserken QRS sivrililiğini de tıraşlar (genlik kaybı).

- **Çözüm: Daubechies (db4) Dalgacık Dönüşümü.** Evrensel eşik ($\sigma * \sqrt{2 * \log(N)}$) kullanılarak, sadece gürültü karakterindeki yüksek katsayılar "Soft Thresholding" ile sıfırlanır, QRS morfizmi %100 korunarak sinyal yeniden inşa edilir.

3.3 Optimizasyon İçin Z-Score (Standartlaştırma) Geometrisi

Derin sinir ağlarının ağırlık güncellemelerinde patlayan veya sönen gradyan (Exploding/Vanishing Gradient) problemini önlemek için EKG sinyali normalize edilmelidir.

- Min-Max ([0, 1]) yerine Z-Score Standardization ($(X - \mu) / \sigma$) kullanılır. Çünkü Min-Max, tek bir hatalı sensör sıçramasında (Outlier) tüm sağlıklı veriyi sıfıra sıkıştırır. Z-Score, modelin genliğe değil sinyalin "geometrisine (şekline)" odaklanmasını mecbur kılar.

Basit Özet : Hastanın nefes alması veya kaslarının seğirmesi, grafiğin üzerine bir çizirtili (kir) bırakır. Klasik süzgeçler bu kiri silerken kalp dalgalarını da ezer, yerini kaydırır. Bizim kullandığımız *Sıfır-Fazlı (FiltFilt)* ve *Dalgacık Dönüşümü (Wavelet)* algoritmaları, sanki bir fotoğrafın sadece pürüzlerini silen yapay zeka fırçası gibi, ana resmi (EKG dalgasını) hiç bozmadan pürüzsüzleştirir.

4. EKG Verisinde Derin Öznitelik Mühendisliği (Advanced Feature Engineering)

Ağaç tabanlı modellerin (XGBoost) besleneceği veritabanını oluşturmak için, ham EKG vektöründen deterministik özellikler çıkartılması gerekir.

4.1 İleri İstatistiksel ve Fraktal Metrikler

- **Zaman Alanı (Time-Domain):** SDNN (R-R aralıklarının standart sapması) ve pNN50. Ek olarak, T-Wave Alternans (TWA) varyasyonu çıkarılarak ani ölüm risk modellerine mikro-parametreler sağlanır.
- **Frekans Alanı (Frequency-Domain):** Welch metodu ile Güç Spektral Yoğunluğu (PSD) çıkarılır. LF/HF oranı otonomik stabilitenin temel taşıdır.
- **Kaos ve Non-Lineer Dinamikler (Önemli!):**

Örneklem Entropisi (Sample Entropy - SampEn): R-R zaman serisindeki yeni bir örüntünün, geçmiş örüntüleri takip etme olasılığının negatif doğal logaritmasıdır. Kalp yetmezliğinde ritim mekanikleşir, Entropi düşer.

Poincaré Dağılım Geometrisi: R_i değerinin, R_{i+1} değerine göre çizilmesiyle oluşan kümenin kısa eksen (SD1) ve uzun ekseninin (SD2) çıkarılması.

4.2 EDR (ECG-Derived Respiration) - Sensörsüz Solunum Çıkarımı

ADS1293'te fiziksel bir nefes sensörü olmamasına rağmen, akciğerlerin dolup boşalması göğüs kafesi empedansını değiştirir. Bu genlik modülasyonunun izi sürülerek hastanın Solunum Hızı (Respiration Rate) sinyalden matematiksel olarak çekilir (EDR) ve modelin öznitelik uzayına güçlü bir "Hayati Bulgu (Vitals)" kolonu olarak eklenir.

Basit Özet : Kalbimiz tık-tık diye robot gibi sabit atmaz; gizli bir düzensizliği, bir "kaosu" vardır. Eğer kalp aşırı düzenli atmaya başlarsa bu aslında bir hastalık belirtisidir (Entropinin düşmesi). Biz, matematiksel formüllerle o sinyalin içindeki karmaşayı hesaplayıp modele "Bak bu kalp çok robotik atıyor, hastada kalp yetmezliği olabilir" demesini öğretiyoruz.

5. Gerçek Dünya Kaosu ve Veri Artırma (Data Augmentation) Mimarisi

Bir araştırmacıyı sıradan bir öğrenciden ayıran temel faktör, modelin "Hastanede / Gerçek Dünyada" karşılaşacağı veri kirliliğini laboratuvarında simüle edebilmesidir.

5.1 Çok Boyutlu Manifoldlarda Sınıf Dengesizliği Çözümü

Nadir görülen (Ventriküler Fibrilasyon vs.) vakaların azlığı modeli "Accuracy Paradox'a" sürükler (Model her şeye "Normal" der ve %95 başarı elde eder).

- **SMOTE Sınırlarını Aşmak (ADASYN & Borderline-SMOTE):** Standart SMOTE körleme veri üretir. Borderline-SMOTE, yalnızca "Normal" sınıfla "Hastalık" sınıfının tehlikeli bir şekilde kesiştiği karar sınırındaki (Decision Boundary) hastalara odaklanır ve o sınıra sentetik hasta üretir.

```
python
# SMOTE ile Gelişmiş Sentetik Aritmi Verisi Üretimi (Python Şablonu)

from imblearn.over_sampling import BorderlineSMOTE

# Sadece karar sınırındaki riskli (Borderline) vakaları çoğaltır

smote = BorderlineSMOTE(sampling_strategy='minority', k_neighbors=5, m_neighbors=10)

X_resampled, y_resampled = smote.fit_resample(X_train_features, y_train_labels)
```

5.2 Zaman Serisinde İleri Augmentation (Bozma ve Zenginleştirme)

Eğitim setini zenginleştirmek için veriye deterministik bozulmalar (Data Corruption) enjekte edilir:

- **Temporal Warping (Zamansal Çarpıtma):** Sinyalin bazı bölümlerinin hızlandırılıp yavaşlatılmasıdır (Dynamic Time Warping mantığı). Farklı hastaların kalplerinin farklı anlarda (QT uzaması) kasılmasını simüle eder.
- **Permutation (Parçalayıp Değiştirme):** Bir EKG sinyali parçalara bölünüp sırası değiştirilir.
- **Sensor Drop-out ve Gaussian Masking:** Elektrot temassızlığını modele öğretmek için, EKG serisinin rastgele seçilen %10'luk kısımlarının matris genliği (0.0) değerine çekilir (Dropout).

Basit Özet : Yapay zekayı bir şoför gibi düşünün. Sadece boş otobanda eğiterseniz şehir trafiğinde kaza yapar. Hastane de şehir trafiği gibidir; kablo kopabilir, hasta hareket edebilir. Bu yüzden laboratuvar da veriye bilerek gürültü ekliyor, kablonun koptuğu anları simüle ediyoruz. Ayrıca az rastlanan hastalık verilerini de akıllı algoritmalarla (SMOTE) sanki binlerce hasta varmış gibi matematiksel olarak çoğaltıyoruz.

6. Uzamsal-Zamansal (Spatio-Temporal) Derin Öğrenme Mimarisi: Neden Hibrit?

Piyasadaki tekil algoritmaların (sadece XGBoost veya sadece CNN) kapasitesi gerçek EKG anomali spektrumunu yakalamaya yetmez. Bu projede, alanın en güçlü, En İleri (State-of-the-Art) Hibrit yapısı önerilmektedir: **1D-CNN + BiLSTM + Attention Mechanism**.

6.1 Mimarinin Anatomisi ve Algoritmik Gerekçeler

- **Aşama 1: 1D-CNN (Mekansal / Spatial Örüntü Avcısı):** Ham 1D veri evrişim (Convolution) katmanına girer. Farklı Kernel boyutları (kernel_size=31 yavaş T dalgasını, kernel_size=7 keskin QRS'i yakalamak için) paralel uygulanır. **Batch Normalization** ile normalize edilerek İç Ortak Değişken Kayması (Internal Covariate Shift) önlenir.
- **Aşama 2: BiLSTM (Zamansal / Temporal Bağlam):** CNN'den çıkan morfolojik haritalar, zaman serisi mantığıyla çalışan Çift Yönlü Uzun-Kısa Süreli Bellek (BiLSTM) ağına verilir. Model sinyali ardışık atımların (ritim bozukluklarının, AFib) uzak mesafeli bağımlılıklarını (Long-term Dependencies) öğrenir.

- **Aşama 3: Bahdanau / Luong Attention (Dikkat Mekanizması):** Modelin tüm sinyale eşit ağırlık vermesi yanlıştır. Dikkat Katmanı, sadece aritmik dalgalara (kriz anına) yüksek katsayı (ağırlık) atar.

6.2 Algoritmik Performans Analiz Matrisi

Hangi algoritmanın hangi durumda kullanılması gerektiğine dair karar matrisi aşağıdadır:

Algoritma Tipi	Yakaladığı En İyi Anomali Tipi	İşlemci (Donanım) İhtiyacı	Öznitelik İhtiyacı
XGBoost	Tablosal veriler, Ritim Analizi, Stres Ölçeği	Çok Düşük (CPU / Mikrodenetleyici)	Yüksek (NeuroKit2 vb. gerekir)
1D-CNN	Morfolojik Bozukluklar (Örn: ST Elevasyonu)	Yüksek (GPU hızlandırma)	Yok (Ham sinyali kullanır)
BiLSTM	Ardışık Ritim Bozuklukları (Örn: AFib, PVC)	Yüksek (GPU veya TPU)	Yok (Ham sinyali kullanır)
Hibrit Ağ	Tüm Olası Komplikasyonlar (Altın Standart)	Çok Yüksek (Bulut / Kapsamlı GPU)	Yok (Sinyalden kendi öğrenir)

Basit Özet : Sinyali en iyi şekilde anlamak için üç uzmanın aynı anda çalıştığını hayal edin. **1D-CNN (Mekansal ağ)**, EKG eğrisinin resmine bakıp şekilsel bozuklukları avlar. **BiLSTM (Zamansal ağ)**, zaman tüneline dolaşarak ritimdeki gecikmeleri arar. **Attention (Dikkat mekanizması)** ise bu ikisine "Sinyalin o düz boş yerlerine bakmayın, doğrudan krizin yaşandığı tepeye odaklanın" der. Bu üçlünün (hibrit yapı) birleşimi sayesinde en zor ritim bozukluklarını bile kaçırmayız.

7. Model Eğitiminde Kritik Stratejiler: Kayıp, Gradyan ve Transfer

7.1 Cross-Entropy'nin Çöküşü ve Focal Loss Matematiği

Dengesiz veri setlerinde standart Çapraz Entropi (Cross-Entropy), %90 oranındaki "Normal" sınıftan gelen kolay gradyan güncellemeleriyle boğulur.

1. **Focal Loss (Odaklanmış Kayıp):** Formülündeki $(1 - p_t)^{\gamma}$ modülatör faktörü sayesinde, modelin çok iyi bildiği örneklerin kayıp değerini sıfıra indirir. Buna karşılık, zor ayırt edilen nadir aritmi sınıflarından gelen hatayı katlayarak büyütür. Ağ, zor örneklerle odaklanmak (Focus) zorunda bırakılır.

7.2 AdamW Optimizasyonu ve Cosine Annealing Öğrenme Oranı

Ağın sahte (yerel) minimumlara (Local Minima) takılmasını önlemek için **Cosine Annealing Warm Restarts (Kosinüs Tavlama)** zamanlayıcısı (LR Scheduler) kullanılır. Öğrenme

oranı kademeli olarak küçülür, dibe vurduğunda aniden yüksek bir değere sıçrayarak (Restart) ağırlıkları sarsar ve modeli daha iyi bir minimum noktasına yönlendirir.

7.3 Transfer Öğrenimi (Transfer Learning)

Sınırlı ADS1293 verisiyle derin ağları sıfırdan eğitmek büyük risktir. Modelin "kardiyak fizyolojiyi" öğrenmesi için, 21.000 hastalık **PTB-XL** veya **PhysioNet** veri setlerinde devasa bir Ön-Eğitim (Pre-training) yapılır. İlk katmanlar dondurulur (Freeze) ve sadece son (karar) katmanlar ADS1293 verisi ile İnce Ayara (Fine-Tuning) sokulur.

Basit Özet : Yapay zekaya bir konuyu öğretirken, çok kolay bildiği şeylerin üzerinde durmasını engellemeliyiz. **Focal Loss** dediğimiz bir ceza sistemi kullanıyoruz; model "Normal" hastaları kolayca tanıyınca onu ödüllendirmeyi bırakıyoruz. Ayrıca **Transfer Öğrenimi** sayesinde, modeli sıfırdan eğitmek yerine, daha önce tıp okuyup mezun olmuş (milyonlarca EKG görmüş) bir modele kendi verilerimizi okutuyoruz.

8. Uç Cihaz Gömülü Yapay Zeka Entegrasyonu (Edge AI & TinyML)

Eğitilen bu devasa modellerin (bulut tabanlı sunucular dışında) doğrudan ADS1293'e bağlı taşınabilir bir donanımda (Giyilebilir Cihaz, Akıllı Saat, Mikrodenetleyici) çalışabilmesi için verinin ve modelin sıkıştırılması şarttır.

8.1 Model Kuantizasyonu (Quantization-Aware Training)

Derin öğrenme modellerinin ağırlıkları normalde 32-bit Kayan Nokta (Float32) formatındadır. Bu modeller C++ tabanlı bir mikrodenetleyicide çalışamaz.

- **Çözüm:** Modelin içindeki tüm ağırlık ve aktivasyon değerleri 8-bit Tam Sayı (Int8) formatına sıkıştırılır (Quantization). Bu işlem model boyutunu 4 kat küçültürken, güç tüketimini (Batarya ömrünü) dramatik şekilde iyileştirir. Performans kaybını önlemek için model baştan "Quantization-Aware Training (QAT)" ile eğitilir.

8.2 Pruning (Budama) ve ONNX / TensorRT Çalışma Zamanı

Ağın içerisindeki sıfıra yakın (önemsiz) ağırlık bağlantıları matematiksel olarak kesilip atılır (Weight Pruning). Ardından eğitilmiş model, PyTorch ortamından çıkarılarak platform bağımsız ONNX veya TensorRT formatına export edilir. Bu format, veri çıkarım (Inference) süresini milisaniyenin altına düşürür.

Basit Özet : Dev bir yapay zeka beynini, kol saati kadar küçük bir cihazın içine sığdıramayız. "Kuantizasyon" ve "Budama" (Pruning) dediğimiz yöntemlerle, yapay zekanın sahip olduğu

gereksiz bilgileri siliyor, dosyayı bir nevi "zip"liyoruz. Böylece internete (buluta) hiç ihtiyaç duymadan, kalp analizini doğrudan hastanın üzerindeki o küçük cihazda anlık olarak yapabiliyoruz.

9. Klinik Şeffaflık ve Optimizasyon: XAI ve Değerlendirme

9.1 Performans Metrikleri: Accuracy'nin Yetersizliği

Tıbbi yapay zekada "Accuracy (Doğruluk)" son derece aldatıcıdır. Araştırmada modelin başarısı **AUPRC (Area Under the Precision-Recall Curve)** ve **F1-Macro Skoru** ile ölçülür. AUPRC, dengesiz veri setlerinde gerçek başarıyı gösteren en acımasız ve net metriktir.

9.2 Karar Sınırı Kalibrasyonu: Youden's J İndeksi

Yapay zeka Softmax fonksiyonundan [Normal: 0.6, Hasta: 0.4] oranları verdiğinde, standart 0.50 barajı (Threshold) kullanılırsa hasta "Normal" ilan edilir ve ölüme sebebiyet verilebilir.

- ROC eğrisi üzerindeki Optimum Karar Noktası; **Youden's J = Duyarlılık (Sensitivity) + Özgüllük (Specificity) - 1** formülü ile maksimize edilir. Modelin hasta ilan etme eşiği dinamik olarak (örneğin 0.23'e) düşürülerek, kritik hastalıkların kaçırılması ihtimali minimize edilir.

9.3 Açıklanabilir Yapay Zeka (Explainable AI - XAI) Şeffaflığı

Kara kutu modeller medikal regülatörler (FDA / MDR) tarafından onaylanamaz.

- **SHAP (XGBoost İçin):** Shapley Oyun Teorisine dayalı olarak; "Model neden hastaya kalp yetmezliği dedi?" sorusunu kantitatif olarak yanıtlar. *"Kararın %45'i SampEn (Entropi) düşüklüğü, %25'i LF/HF dengesizliği nedeniyle."* diyerek şeffaf waterfall grafikleri üretir.
- **Grad-CAM (Derin Öğrenme İçin):** 1D-CNN'in karar verirken sinyalin neresine odaklandığını bulmak için EKG sinyali üzerine Isı Haritası (Heatmap) çıkarır. Model "ST Yükselmeli Enfarktüs" dediğinde, ısının doğrudan **ST Segmentinin olduğu yere** düşmesi sağlanarak, doktorlara yapay zekanın "ezberlemediği, fizyolojiyi gerçekten öğrendiği" grafiksel olarak kanıtlanır.

Basit Özet : Yapay zeka %99 doğru çalışsa bile bir doktora güven veremez çünkü "Neden o kararı verdin?" sorusu yanıtsızdır. Bizim sistemimizdeki **Grad-CAM (Isı Haritası)**, EKG çizgisinin üzerine kırmızı renkle bir odak noktası çizer. Yapay zeka doktora adeta; *"Ben bu kişinin hasta olduğunu söyledim çünkü bak çizginin tam şu noktasına baktım, burada bir çöküntü var"* der. Bu sayede yapay zeka bir "kara kutu" olmaktan çıkıp, şeffaf bir asistana dönüşür.