

Biz veriyi sadece toplamıyoruz, onu giyilebilir bir cihazın hareketli kaosundan kurtarıyoruz.

Emg yürüme görüntülerini sıfır fazlı ve dalgacık algoritmalarıyla filtreleriyle siliyoruz

Butterworth adında çok ünlü bir matematiksel süzgeç üretiyoruz. Bu süzgecin özelliği, sinyali keserken çok pürüzsüz bir eğri çizmesidir. Çıkan b ve a değerleri, bu süzgecin matematiksel katsayılarıdır.

Saniyede 500 örnek ($f_s=500$) gelen bir EKG verimiz var. Bu verinin içindeki 0.5 Hz'den düşük (hastanın nefes almasından kaynaklı yavaş dalgalanmaları) ve 40 Hz'den yüksek (kas titremesi, kablo sürtünmesi gibi hızlı cızırtıları) her şeyi çöpe at." Böylece sadece gerçek kalp atışının frekansı kalır.

Cihaz veriyi işlemeye yetişemezse diye ring buffer ve interrupt kullanırız işlemci sürekli çipe gidip veri hazır mı diye sormaz bu işlemleri yavaşlatır o yüzden interrupt kullanırız o da veri hazır olduğunda cpuya haber verir işlemcide veriyi alıp ring buffera koyar yani sıra oluşturur veriler bir anda girip çökme olmasın diye

- Bu kadar çok özelliği (67+) model nasıl hızlı işleyecek?"
- **Savunman:** *"Modellerimiz Z-Score normalizasyonu sayesinde veri genliğine değil, verinin saf geometrisine odaklanacak şekilde optimize edildi. Vektörize edilmiş NumPy işlemleriyle bu özellikler $O(1)$ zaman karmaşıklığında anlık olarak çıkarılıyor."*

Modül 1: Donanım-Yazılım Arayüzü ve Ham Veri Akışının Yönetimi

Giriş:

"Projemizin ilk aşaması, donanım katmanından gelen ham verilerin kayıpsız bir şekilde yazılıma aktarılmasıdır. Hastanın belinde taşıdığı giyilebilir bir Holter cihazı, hastane odasındaki durağan monitörlere göre çok daha agresif ve dinamik bir veri akışına sahiptir. Bu aşamada temel amacımız; veri kaybını sıfıra indirmek ve çiplerin ürettiği şifreli ham veriyi tıbbi olarak anlamlı kılmaktır."

1. Sigma-Delta ($\Sigma\Delta$) ADC ve Kesintisiz Veri Akışı (Ring Buffer)

"Kalpten cilde yansıyan sinyaller mikrovolt seviyesindedir. ADS1293 çipi bu sinyalleri yakalayarak ardışık bir aşırı örnekleme tabi tutar ve gürültüyü 'Sinc' filtre zinciriyle arındırır.

Modül 2: Giyilebilir Sistemlerde Ham Veri Temizleme ve Gürültü İzolasyonu

Giriş:

"Veriyi kayıpsız aldık ancak giyilebilir cihazlarda hastanın yürümesi, nefes alması veya kıyafetinin kabloya sürtünmesi (Motion Artifact) devasa bir gürültü yaratır. Klasik filtreler bu gürültüyü silerken kalp dalgalarını da ezer ve şeklini bozar. Biz sinyali pürüzsüzleştirirken tıbbi yapısını korumak için ileri sinyal işleme algoritmaları entegre ettik."

1. Düşük Frekans Kayması ve Sıfır-Fazlı İzolasyon (FiltFilt)

"Hastanın nefes alıp vermesi sinyale 0.1 - 0.5 Hz arasında periyodik bir parazit ekler. Bu parazit, EKG çizgisinin yukarı aşağı dalgalanmasına (Baseline Wander) yol açar.

Eğer standart bir IIR filtre kullansaydık, sinyal zaman ekseninde sağa doğru kayacak ve kritik bir metrik olan QT süresi bozulacaktı. Çözüm olarak **Forward-Backward (Sıfır-Fazlı) filtreleme**, yani **FiltFilt** tekniğini uyguladık. Sinyali zaman ekseninde önce ileri, sonra geri işleterek faz kaymasını matematiksel olarak sıfırlıyor ve çizgiyi merkeze sabitliyoruz."

2. Kapsamlı Wavelet Denoising (Dalgacık Dönüşümü)

"En büyük zorluklardan biri de yürürken kaslardan yayılan EMG gürültüsüdür. Çünkü bu gürültü, kalbin QRS dalgasıyla aynı frekans aralığındadır. Klasik süzgeçler burada çaresiz kalır ve tepe noktalarını ezer.

. Evrensel bir eşik değeri hesaplayarak, sadece gürültü karakterindeki katsayıları 'Soft Thresholding' yöntemiyle sıfırlıyoruz. Tıpkı bir fotoğrafın pürüzlerini silen ama ana resmi hiç bozmayan bir yapay zeka fırçası gibi, QRS morfolojisini %100 koruyarak sinyali temizliyoruz."

Modül 3: EKG Sinyalinin Morfolojik Analizi ve Özellik Çıkarımı

Giriş: "Ham veriyi gürültüden arındırdık, ancak XGBoost gibi modeller bu temizlenmiş çizgilere bakıp kendi başına 'burada bir hastalık var' diyemez.

1. Pan-Tompkins ile Hatasız Tepe Tespiti "Öncelikle kalp atış hızını bulmak için en büyük tepe olan R-tepesini milisaniyelik hassasiyetle yakalamalıyız. Hareket halindeki bir hastada basit bir eşik (threshold) değeri belirlemek anında çöker, çünkü sinyalin genliği sürekli değişir.

Bunun yerine **Pan-Tompkins Algoritmasını** kullanıyoruz. Sinyali sırasıyla şu filtrelerden geçiriyoruz:

Türev Alma

Kare Alma

Hareketli Pencere İntegrali: Sinyalin alanını hesaplayarak sadece gerçek kalp atışlarını izole ediyoruz. Bu sayede hasta koşsa bile R-tepelerini sıfır hatayla buluyoruz."

1. R-Tepelerini Bulmak Ne İşe Yarıyor? (Neden Bu Kadar Önemli?)

Kalp Atış Hızını (BPM) Bulmak:

Kalp Atış Hızı Değişkenliğini (HRV) Ölçmek:

Sinyali Dilimlemek (Referans Noktası):

2. İleri İstatistiksel ve Frekans Analizleri "Tepeleri bulmak buzdağının sadece görünen kısmı. Bu tepeler arasındaki mesafeleri (R-R aralıkları) derinlemesine analiz ediyoruz:

- **Zaman Alanı (Time-Domain):** SDNN (R-R aralıklarının standart sapması) gibi metrikleri çıkararak ani kalp durması risklerine dair mikro-parametreler elde ediyoruz.
- **Frekans Alanı (Frequency-Domain):** Welch metodunu kullanarak sinyalin Güç Spektral Yoğunluğunu (PSD) çıkarıyoruz. Buradan elde ettiğimiz LF/HF (Düşük Frekans / Yüksek Frekans) oranı, bize doğrudan hastanın otonomik stres dengesini veriyor."

3. Non-Linear Dinamikler: Kalbin Gizli Kaosu "Burası mimarimizin en kritik noktası. Genel kanının aksine, sağlıklı bir insan kalbi metronom gibi tık-tık sabit atmaz; içinde gizli bir 'kaos', karmaşık bir fraktal yapı vardır.

- Eğer bir kalp aşırı düzenli ve mekanik atmaya başlarsa, bu kalp yetmezliği gibi ciddi bir hastalığın belirtisidir.
- Biz bu durumu tespit etmek için **Örnekleme Entropisi (SampEn)** kullanıyoruz. Entropi, zaman serisinin karmaşıklığını ölçer.

• **Modül 4: Veri Artırma (Data Augmentation) ve Dengesizlik Çözümü**

- **Giriş:** "Özelliklerimizi çıkardık ama medikal verilerde çok büyük bir problem var: Dengesizlik. Veri setimizin %90'ı sağlıklı insanlardan, çok küçük bir kısmı ise kriz anlarından oluşuyor. Eğer modeli bu haliyle eğitirsek model 'Accuracy Paradox'a (Doğruluk Paradoksu) düşer; yani herkese 'Normal' diyerek kağıt üzerinde %95 başarılı görünür ama asıl hastaları kaçıır. Bunu laboratuvarında iki stratejiyle çözüyoruz."
- **1. Borderline-SMOTE ile Sınırları Keskinleştirme** "Standart sentetik veri üretme yöntemleri (SMOTE) veriyi körlemesine çoğaltır. Biz ise **Borderline-SMOTE** kullanarak sadece 'Normal' ile 'Hastalık' sınıflarının tehlikeli bir şekilde birbirine karıştığı o ince karar sınırına (Decision Boundary) odaklanıyoruz. Sentetik hastaları tam olarak modelin kafasının karıştığı bu gri bölgelerde üretiyoruz."

2. Gerçek Dünya Simülasyonu (Zaman Serisi Augmentation)

- **Zamansal Çarpıtma (Temporal Warping):** Sinyalin belirli kısımlarını hızlandırıp yavaşlatarak farklı hastaların kalp kasılma hızlarını simüle ediyoruz.
- **Sensor Drop-out (Sensör Kopması):** Giyilebilir cihazda elektrotun terden dolayı ciltten anlık ayrılma ihtimaline karşı, EKG serisinin rastgele kısımlarını sıfırlayarak (0.0) modele veri kaybı anında bile karar vermeyi öğretiyoruz."

Modül 5: Uzamsal-Zamansal (Spatio-Temporal) Derin Öğrenme Mimarisi

Giriş: "Ham veriyi tek bir algoritmaya emanet etmek, gerçek dünyadaki karmaşık kalp krizlerini yakalamak için yetersizdir. Bu yüzden literatürdeki en ileri (State-of-the-Art) hibrit mimariyi kurduk. Sinyali analiz etmek için üç farklı uzmanı aynı anda çalıştırıyoruz."

1. Şekil Avcısı: 1D-CNN "İlk aşamada ham veri 1D-CNN (Evrişimli Sinir Ağı) katmanına girer. Farklı çekirdek boyutlarıyla (örneğin yavaş T dalgası için geniş, keskin QRS için dar filtreler) **EKG'nin görsel ve morfolojik haritasını, yani şekil bozukluklarını çıkarıyoruz."**

2. Zaman Yolcusu: BiLSTM "CNN şekle bakar ama zamanı anlamaz. CNN'den çıkan bu haritaları, Çift Yönlü Uzun-Kısa Süreli Bellek (BiLSTM) ağına aktarıyoruz. **BiLSTM sinyali ileri ve geri okuyarak ardışık atımlar arasındaki gizli gecikmeleri ve ritim bozukluklarını (örneğin Atriyal Fibrilasyon) yakalıyor."**

3. Odaklanma: Attention (Dikkat) Mekanizması "Son olarak, modelin tüm 10 saniyelik sinyale eşit ağırlık vermesini engelliyoruz. Dikkat Mekanizması sayesinde yapay zekaya; 'Bütün çizgiye bakma, sadece krizin yaşandığı o anormal tepe noktasına yüksek katsayı ata' diyoruz."

• **Derin Öğrenme Hattı (Sıralı İşleyiş):** * Ham dalga önce **1D-CNN'e** giriyor (CNN şekilsel bozuklukları, ST çökmelerini yakalıyor).

- CNN'in ürettiği anlamlı özet harita, hemen arkasından **BiLSTM'e** aktarılıyor (BiLSTM zaman tüneline ritim kaçıklıklarını yakalıyor).
- BiLSTM'in çıktısı **Attention (Dikkat)** katmanına giriyor (Attention kriz anındaki tepeye odaklanıyor) ve bir "Hastalık Olasılığı" (Örn: %85 Risk) üretiyor.

• Sinyalin şekli CNN'den **BiLSTM'e** doğru sıralı bir derin öğrenme hattına akarken, sinyalin matematiği tablosallaştırılarak **XGBoost'a** gider. Bu iki farklı beynin ürettiği tahminler **Modül 5'in sonunda Karar Füzyonu ile birleştirilir**, nihai başarı kıyaslamaları ise **Modül 8'de klinik metriklerle** yapılır."

Modül 6: Model Eğitimi, Optimizasyon ve Kayıp Fonksiyonları

Giriş:

"Bu devasa mimariyi eğitirken klasik yöntemler kullanırsak ağımız tembelleşir. Ağın eğitim sürecini agresif ve odaklı tutmak için özel matematiksel cezalar uyguluyoruz."

1. Çapraz Entropinin Çöküşü ve Focal Loss

"Klasik Cross-Entropy, model çok sayıda 'Normal' hastayı doğru bildiğinde modeli sürekli ödüllendirir. Biz bunun yerine **Focal Loss** kullanıyoruz. Formülündeki $(1 - p_t)^\gamma$ çarpanı sayesinde, modelin çok iyi bildiği örneklerde cezayı sıfıra indiriyoruz. Ağ, öğrenmesi zor olan nadir aritmilerde hata yaptıkça cezayı katlayarak büyütüyoruz. Böylece modeli zor olanı öğrenmeye mecbur bırakıyoruz."

2. AdamW ve Transfer Öğrenimi

"Ayrıca, yapay zekanın yerel minimumlarda (sahte başarılarda) takılıp kalmaması için öğrenme oranını aniden sarsan (Cosine Annealing) bir optimizasyon yapıyoruz. En önemlisi, modeli sıfırdan eğitmek yerine on binlerce EKG görmüş hazır modellerin ağırlıklarını kullanarak (Transfer Learning) sisteme önceden kardiyoloji eğitimi veriyoruz."